

LLM Hypothesis Citation Agent

引文幻觉审计系统·技术架构报告

刘炎男

郭耀远

12311122@mail.sustech.edu.cn 12312902@mail.sustech.edu.cn

齐佳男

12311812@mail.sustech.edu.cn

June 5, 2026

1 引文幻觉验证系统概览

大语言模型在生成科学假设时会附带引用文献来支撑其主张，但这些引文存在幻觉风险——模型可能编造不存在的论文、虚构DOI、或将真实文献的内容张冠李戴。本系统是一个针对此类引文幻觉的后审计管道：它不关心假设本身是如何生成的，只关心假设所依赖的引文是否真实存在、元数据是否正确、以及被引文献的内容是否确实支撑模型所声称的主张。

系统的输入来自DeepScientist¹——一个开源的科学发现代理框架，以Claude 作为推理后端，读取论文PDF、检索相关文献、生成研究假设并以JSON 格式输出引文主张。DeepScientist 在此仅作为上游数据源，其内部实现不在本系统的关注范围内。本系统的核心价值在于下游：对每一引文主张进行独立于LLM 的事实核验。

整体管道为五阶段流水线：

- 输入接收**：从DeepScientist 输出的claims JSON 中提取每条引文主张及其被引文献元数据（标题、作者、年份、DOI、检索来源）。
- 规范化与富化**：Claims Normalizer 将多格式输出统一为验证器所需的规范schema；Claims Enricher 利用源论文元数据补全匹配引文的缺失字段。
- 逐条引文审计**：CitationVerifier 对每条claim 执行四个API 的交叉验证——存在性查找、元数据比对、支撑度评分——最终赋予Green（材料明确支撑）、Yellow（合理推断但未直接证明）或Red（证据不足）标签。
- 多模型平行评审**：四位不同提供商的LLM 作为平行评审者，独立对完整审计结果评分（1-6分），评分受确定性上限约束。
- 跨运行记忆归档**：每次审计的引文标签历史、API 可靠性统计和评审决策写入持久化JSONL 记忆，用于跨运行幻觉模式识别。

在批处理层面，系统在15 篇跨领域真实论文上进行了泛化压力测试，覆盖NLP、医学影像、量化金融、物理学、材料科学、神经科学、机器人、气候遥感、教育等学科，验证了审计管道在不同领域引文模式下的稳定性。

¹<https://github.com/ResearAI/DeepScientist>




Figure 1: 引文幻觉审计管道：从论文输入到跨运行记忆归档的五阶段流程。系统的核心在第三、第四阶段——确定性验证与多模型评审——而非假设生成本身。

2 引文验证管道

2.1 上游：假设与引文的来源

系统接收的claims 数据可以来自两条路径。主路径使用DeepScientist 作为代理，由Claude 运行器读取论文、检索文献、生成假设并输出结构化JSON。回退路径使用本地CitationAuditClaimsGenerator，在DeepScientist 不可用时通过PdfReaderTool + LiteratureSearcher + HypothesisGenerator 本地生成。无论来源如何，所有引文主张在进入验证管道前均经过Claims Normalizer 归一化为统一schema。

需要强调的是，系统对假设的生成策略不作评判——假设是否新颖、方法论是否合理，这些问题由后续的Multi-Reviewer 从证据质量角度间接评估。验证管道的唯一任务是逐条核验每条引文主张的事实准确性。

2.2 核心：确定性引文验证

CitationVerifier 是系统的核心组件，对每条claim 执行四阶段检查，全程不依赖LLM 判断：

1. **存在性查找**：通过DOI 或标题在Crossref、OpenAlex、Semantic Scholar 和arXiv 四个公共API 上查询。DOI 精确查找优先，未命中则按标题搜索，结果按引用数降序排列。
2. **版本消歧**：当同一文献在多个数据源存在不同记录时（如preprint 与正式发表版本），按DOI 精确匹配优先、标题-作者相似度次之的规则合并去重。
3. **元数据比对**：综合评估标题文本相似度、作者Jaccard 重叠度、发表年份差异和DOI 精确匹配，判断被引文献的元数据是否与公开记录一致。
4. **支撑度评分**：将被引文献的abstract 或snippet 与claim 文本进行句子级覆盖分析，计算文本重叠分数和关键词覆盖率，检测是否存在数值矛盾或条件冲突等硬性错误。

综合打分后，每条claim 归入三级标签：

- **Green（材料明确支撑）**：文献在公共API 上确认存在、元数据匹配、abstract 文本直接支撑claim 主张。需通过九条件Green Gate 全部判定。
- **Yellow（合理推断但未直接证明）**：文献存在且元数据基本匹配，但abstract 对claim 的支撑是间接的、部分的或不确定的。例如claim 声称某个方法有效，被引文献提出了该方法但未提供实

验验证。

- **Red (证据不足)**：文献未找到、DOI 无效、元数据严重不匹配，或存在硬性矛盾（如claim 声称的数值与文献记录不一致）。

2.3 LLM 的使用边界

LLM 在整个验证管道中仅在两个环节被调用：上游的HypothesisGenerator 中用于生成假设（创造性任务），以及CitationVerifier 中可选的单句解释生成（仅用于人工阅读参考，内部约束不得据此修改标签）。所有真值判断——引文是否存在、元数据是否正确、abstract 是否支撑主张——均由确定性API 查询和规则判定完成。这一设计选择基于实测观察：LLM 在事实核验任务上存在确认偏误，倾向于将听上去合理的引文标记为真实。

3 Tool-Use 双层架构

系统的工具调用采用双层设计：上游代理层使用LLM 函数调用自主检索文献以生成假设，下游验证层使用确定性API 查询完成逐条引文的事实核验。两层通过工作流编排器衔接，所有工具调用的输入输出和耗时全量记录到审计日志。

3.1 代理层：LLM 驱动的文獻检索

HypothesisGenerator 是系统中唯一使用LLM 函数调用的组件。它注册一个`search_literature` 工具——接受搜索查询字符串数组、返回学术论文元数据。代理循环限制为最多三轮：LLM 接收论文摘要后自主决定是否调用工具；若调用，工作流提取查询参数，通过LiteratureSearcher 依次查询Crossref、OpenAlex、Semantic Scholar 和arXiv，合并去重后以tool message 格式回传结果；LLM 评估后决定继续搜索或输出最终JSON。三轮结束后强制输出结构化结果。

3.2 验证层：四个公共API 的交叉查询

CitationVerifier 不使用LLM 函数调用。四个查询函数分别封装Crossref、OpenAlex、Semantic Scholar 和arXiv 的HTTP 请求，按固定管道顺序执行：Lookup → Version Resolution → Metadata Matching → Support Scoring → Classification。LLM 仅用于生成人类可读的审核说明，不参与判定。

3.3 审计追踪

每次工具调用都通过ToolCallLogger 写入`tool_calls.jsonl`（含调用ID、时间戳、工具名、耗时、状态和错误信息）。EvidenceStore 将各工具产出的证据项以证据ID 关联回对应的工具调用，写入`evidence_items.jsonl`。两个日志共同构成从工具调用到证据项的完整审计链路。

4 Research Memory 双层记忆

系统包含两套独立的记忆机制，分别面向不同时间尺度的幻觉风险。ResearchMemory 以文件持久化追踪跨运行引文可靠性；AgentMemory 以层级结构记录代理行为模式并自动归并为长期规则。




Figure 2: 双层工具调用架构。左侧LLM Agent 使用函数调用检索文献（虚线表示3 轮循环），右侧验证层以确定性API 查询逐条核验引文事实。

4.1 ResearchMemory: 跨运行引文审计记忆

ResearchMemory 是基于JSONL 的持久化存储，覆盖五类文件：

- **Citation Memory:** 按DOI 或规范化标题键upsert，累积每次运行中该引文的标签历史（label_history）和最新标签（latest_color_label）。
- **Provider Memory:** 记录各数据源在每次运行中的成功/失败/错误计数。
- **Reviewer Memory:** 追加式记录每次多评审面板的评分和决策（append-only，每轮评审均视为独立历史证据）。
- **Failure Memory:** 按复合键upsert，存储Yellow/Red 级别的引文风险项及case 级失败记录。
- **Case Memory:** 记录每个case 每次运行的Green/Yellow/Red 分布和最终评分。

跨运行反幻觉的三个机制：其一，当某DOI 在历史运行中曾被标记为Red，Multi-Reviewer 会收到完整标签历史作为评审上下文；其二，跨运行累积的API 错误计数帮助识别不可靠数据源；其三，merge_label_history 确保历史标签不被覆盖，latest_color_label 反映最新运行结果。

4.2 AgentMemory: 层级化反思记忆

AgentMemory 采用Working / Short-term / Long-term 三层架构。Working Memory 记录单次运行的计数器；Short-term Memory 积累近期的成功经验和验证错误；当某类错误累积超过30 条时自动压缩为Long-term rule；成功模式出现三次以上则晋升为Long-term success_pattern。反思数据中记录了三类高频幻觉：元数据伪造、过度推断、引文无关——这些反思注入系统提示使代理携带对过往错误的记忆。

5 Multi-Reviewer 多模型平行评审

Multi-Reviewer 是运行于确定性引文验证之后的评分面板。它对完整假设包中的每条引文审计结果进行综合评分，产出1-6 分的最终分值和Accept / Revise / Reject 三级决策。其核心约束是：确定性验证结果（Green/Yellow/Red 标签分布）在评分上具有优先权——LLM 评审不能通过高估计分来掩盖引文层面的证据缺陷。

5.1 评分体系：证据质量三阶梯

Multi-Reviewer 的1-6 评分直接对应引文的证据支撑质量，而非假设的新颖性或方法论合理性：

分数越高代表引文证据质量越强。评分不是对假设本身优劣的评判，而是对假设所依赖的文献证据链完整性的度量。




Figure 3: 双层记忆架构。左侧ResearchMemory 追踪跨运行引文级一致性，右侧AgentMemory 纠正单代理行为偏差。

Table 1: 评分与证据质量对照

分数	标签	证据等级	含义
1-2	Red	证据不足	引文未在公共API 上找到，或DOI 无效，或元数据与被引文献严重不匹配，或存在硬性数值矛盾。假设的主张缺乏可验证的文献支撑。
3-4	Yellow	合理推断但未直接证明	引文在公共API 上确认存在，元数据基本匹配，但被引文献的abstract 或全文对claim 主张的支撑是间接的、部分的或推测性的。例如claim 声称某方法在特定条件下有效，但被引文献仅提出了方法而未经实验验证。
5-6	Green	材料明确支持	引文确认存在，元数据完全匹配，被引文献的abstract 或全文直接、明确地支撑claim 主张。九条件Green Gate 全部通过。

5.2 架构：四模型平行评审

四位评审被配置为完全平行的通用评审者，使用四种不同模型、三个不同API 提供商。每位评审基于相同的审计上下文（引文验证CSV、证据链、API 查询日志、历史记忆命中）独立评分。评审之间不通信、不协调，评分分歧本身即为审计质量的信号。元评审使用DeepSeek V4 Pro，综合四份独立评分后产出加权最终分数和决策标签。

Table 2: 四位平行评审配置

ID	模型	提供商	API 端点	评审范围
R1	deepseek-v4-flash	DeepSeek	api.deepseek.com	通用评审
R2	deepseek-v4-pro	DeepSeek	api.deepseek.com	通用评审
R3	minimax-text-01	MiniMax	api.minimax.chat	通用评审
R4	glm-4-flash	GLM	open.bigmodel.cn	通用评审

5.3 确定性评分上限（Score Cap）

为确保LLM 评审不能通过高估计分掩盖引文层面的证据缺陷，系统基于引文标签分布计算硬性评分上限。Cap 初始值为6，逐级施加封顶规则，取最低触发上限为有效Cap：

Table 3: 确定性评分上限触发规则

触发条件	规则说明	上限
any_red_claim	存在任意证据不足（Red）的引文	2
red_line_error_type	检测到硬性错误（not_found、DOI 无效、数值矛盾）	2
yellow_majority	合理推断（Yellow）占比超过50%	4
no_green_claims	无引文达到材料明确支持（Green）标准	4
support_risk_error	主张过强/ 关键术语缺失/ 数值矛盾	4
risk_penalty_total	确定性风险罚分累计 ≥ 3	4

Cap 为2 时，最终分数被限制在1-2 分（Red 区间），决策强制Reject——即使LLM 给出高估分，也不能将证据不足的引文包装为可接受的假设。Cap 为4 时，最多允许3-4 分（Yellow 区间），决策限制为Revise，禁止Accept。

5.4 双模式运行与降级策略

三种运行模式：auto（检测到API 密钥则用LLM 评审，否则降级为确定性规则评分）、deepseek（强制LLM，密钥缺失仍降级）、deterministic（完全跳过LLM，纯规则评分）。确定性模式基于Green/Yellow/Red 标签分布直接计算分数区间，确保即使所有外部API 均不可用，系统仍能产出有依据的评分结果。

5.5 评审一致性与冲突消解

四位评审的一致程度由分数极差度量：极差不大于1 为高一致性，不大于2 为中一致性，超过2 为低一致性。极端情况下，即使四位LLM 全部给出一致的高分，若引文验证中检出Red 标签，Cap 机制将最终分数截断至2 分（证据不足），决策强制Reject。评审共识不能凌驾于确定性事实之上。

6 实验统计与可复现结果

为避免只展示单次成功案例，本报告对当前项目输出目录中的真实运行产物进行了汇总统计。统计范围包括15x campaign、20x campaign 和local runs 三类输出。统计对象不是人工编写的示例数字，而是已经生成的引文核查表、证据链、工具调用日志和证据记录等可复现文件。

Table 4: 三个输出目录的合计审计规模

统计项	数量	含义
总文件数	1031	三个输出目录下的全部运行文件
总子目录数	179	运行、案例、审计和评审等子目录
citation_verification.csv	29	已生成的引文红黄绿核查表
被审查citation / claim 行数	178	所有核查表中的claim 级审计记录总数
Green / Yellow / Red	57 / 119 / 2	当前三目录合计的最终引文标签分布
evidence_chain.csv 行数	178	与claim 审计行一一对应的证据链记录
tool_calls.jsonl 记录数	1219	PDF 解析、检索、API 查询、审计与评审工具调用日志
evidence_items.jsonl 记录数	797	证据条目、来源片段、工具输出与中间结果
retrieved_literature.jsonl 记录数	471	本地workflow 检索得到的文献记录
multi_review_report.md	22	已生成的多评审报告
meta_decision.json	22	已生成的最终评分与决策记录

Table 5: 分目录Green / Yellow / Red 结果

目录	CSV 数	Claims	Green	Yellow	Red
deepscientist_15x_campaigns	9	64	17	47	0
deepscientist_20x_campaigns	13	85	34	50	1
outputs/runs	7	29	6	22	1
合计	29	178	57	119	2

从统计结果可以看出，Yellow 占比明显高于Green，说明系统采用了保守审计策略：只要公开API 返回的摘要、片段或元数据不足以直接支持claim，就不会强行标Green。Red 数量较少，主要用于无效引用、明显元数据冲突或被证据明确否定的情况。该分布符合本项目的设计目标：优先降低false Green 风险，将不确定证据留给人工复查，而不是用LLM 判断替代证据链核查。

7 实现概要

Table 6: 核心模块

模块	职责
agent/deepscientist_adapter.py	上游适配: claims 标准化 → 富化 → 分发至验证器
agent/deepscientist_claims_normalizer.py	多格式claims 归一化为验证器输入schema
agent/citation_verifier.py	核心: 4 API 交叉查询 + 5 阶段判定管道 + Green Gate
agent/hypothesis_generator.py	search_literature 工具定义 + 3 轮代理循环 (上游)
agent/research_memory.py	跨运行JSONL 记忆: 5 类记录, upsert/append/lookup
agent/agent_memory.py	三层反思记忆: Working → Short → Long, 自动压缩
agent/workflow.py	本地工作流编排 (回退路径)
agent/run_logging.py	审计日志: ToolCallLogger + EvidenceStore
agent/llm_client.py	LLM 工厂: DeepSeek / MiniMax / GLM 统一接口
scripts/run_multi_reviewer.py	4 模型平行评审 + 元评审 + 确定性Cap (1-6 分制)
scripts/run_official_ds_case.py	单案例管道: 接收claims → 审计 → 评审 → 记忆归档
scripts/deepscientist_15x_campaign.py	15 案例跨领域泛化压力测试批处理